Get Start from SparkPi

图解Spark core


@时金魁 花名玄畅 淘宝技术部-数据挖掘与计算-高性能计算

2015-3



Why

现在spark源码解读的博客和书已经很 多了



图片来自500px

focus


- 全局观
- 一个Spark任务完整的执行流程

说明:


- 1. 以图说为主
- 2. 配合graffle图
- 3. shuffleTask略(这块太复杂)

get start from

```
def main(args: Array[String]) {
  val conf = new SparkConf().setAppName("Spark Pi")
  val spark = new SparkContext(conf)
  val slices = if (args.length > 0) args(0).toInt else 2
  val n = 100000 * slices
  val count = spark.parallelize(1 to n, slices).map { i =>
    val x = random * 2 - 1
    val y = random * 2 - 1
    if (x*x + y*y < 1) 1 else 0
  }.reduce(_ + _)
  println("Pi is roughly " + 4.0 * count / n)
  spark.stop()
}</pre>
```




数据流向图



第1步: start driver


初始化: Application, AppClient, task scheduler, backend



第2步: Action->提交job任务


两个函数:

- processFunc ->
 Partition
- 2. mergeResult -> Partition Result




第3步: build final stage(DAGScheduler)

根据依赖关系,生成有序的父RDD列表




第4步: submitStage(DAGScheduler)

- 1. 以partition为最小单元, 封装成最终执行的Task对象
- 2. 转换过程: partition -> TaskLocation -> ShuffleMapTask/ResultTask 最终转化成Task对象, Task对象即将被调度到分散的worker上,给分配线程执行



第5步: lauch tasks(CoarseGrainedSchedulerBackend)


粗粒度后台调度器,向正在running的饥饿的Worker发消息: Task来了



第6步: submitTasks(TaskSchedulerImpl)

分散在各台机器上的Worker是独立启动的main, 它收到新Task消息后:


- 1. 从线程池中分配一个线程,让Executor去执行Task
- 2. Executor会把Task运行时所需的资源准备好: jar, file...



第7步: submitTasks(TaskSchedulerImpl)

这里才是硬菜:


- 1. 反序列化出RDD及应用在partition上的计算函数
- 2. BlockManager从local/remote 拿到MemoryStore/TachyStore/DiskStore上的具体数据
- 3. 应用计算函数






原路返程

第1步:序列化partion执行结果,向上发消息给CoarseGrainedSchedulerBackend



第2步: CoarseGrainedSchedulerBackend封装 StatusUpdate对象,向TaskSchedulerImpl发消息




第3步:序列化partion执行结果,向上发消息

Executor中Task执行结果有两种:


- 1. DirectTaskResult 完整的结果
- 2. IndirectTaskResult 结果信息
 - 一次Akka消息发布出去,就只封装结果信息: TaskResultBlockId和resultSize

TaskSchedulerImpl如果收到 IndirectTaskResult,就要根据 TaskResultBlockId和大小去Worker上 拉结果数据。这是就需要 NettyBlockTransferService干重活了.



第4步: DAGScheduer终结者

- 1. 拿到所有的partition 执行结果
- 合并结果
 返回给app




"一来一去,任务结束"

summary

- Task开箱即跑: Task在Driver上封装好的
- Partition数据: 根据partition id可以确定数据的物理位置
- 中间调度过程: 失败了可以重新提交; 数据丢失了, 可以根据RDD依赖关系重新计算出来

全图:





图片来自500px

招贤纳士

- 1. 推荐算法工程师
- 2. 推荐系统专家
- 3. 开发工程师(Scala/Java)

mailto: mingfeng@taobao.com

Thanks

